



Informe N°1, MCDI500 PROGRAMACIÓN PARA LA CIENCIA DE DATOS

Avance del proyecto, Fase 1 y 2 - Implementación inicial del entorno reproducible, exploración y procesamiento inicial de los datos del proyecto.

Docente: Dr. Omar Salinas Silva

Estudiantes: Matías Manriquez Ortiz, Daniel Pérez Ramirez, Abigail Roblez Chavez,
Roberto Sánchez Saldivia.

Magíster en Ciencia de Datos e Inteligencia Artificial

Universidad Andrés Bello, Santiago.

Santiago, 16 de septiembre de 2026.

I. Índice	2
I. Índice	2
II. Introducción y contextualización	3
III. Definición de la problemática y objetivos del proyecto	5
Formulación de la problemática	5
Preguntas centrales del análisis	5
Objetivo general	6
Objetivos específicos	6
Alcance	7
Supuestos y restricciones	7
Articulación con las fases F1-F4	8
IV. Aplicación de herramientas científicas.	8
Reproducibilidad técnica	9
Control de versiones	9
Documentación del proceso	9
V. Diseño de soluciones algorítmicas eficientes.	11
A. Codificación funcional	11
B. Preprocesamiento y transformación del dataset	12
C. Validación técnica y verificación del código.	12
Notebook F1_Definición.ipynb (F1)	13
Notebooks Ejecutables (F2)	15
Vinculación del mapa conceptual con el avance de proyecto.	18
Referencias	22
Anexos	23

II. Introducción y contextualización

El proyecto se formuló para trabajar con los datos de **Youth Risk Behavior Survey 2023**. La unidad de análisis son estudiantes entre 12 y 18 años que asisten a establecimientos públicos y privados de Estados Unidos. El Archivo contiene más de 20.000 registros, de los cuales se seleccionarán las columnas relacionadas con temas de salud física y mental.

Esta investigación busca estimar la magnitud y dirección de la asociación entre la frecuencia de uso en redes sociales y la salud mental reportada en el YRBS 2023, mediante análisis ponderados. La adolescencia constituye una etapa especialmente relevante para este análisis, dado que en ella pueden manifestarse diversos problemas de salud mental. Sin embargo, tanto la exposición como el resultado de interés deben comprenderse considerando su complejidad. En este sentido Valkenburg et al. (2022) señalan:

Tanto el uso de redes sociales como la salud mental son constructos sumamente complejos. Aunque la mayoría de los estudios se ha concentrado en la relación entre el uso de estas plataformas y la depresión o los síntomas depresivos, también deben investigarse plenamente los demás componentes de la salud mental, incluidos sus factores de riesgo. (p. 60, traducción propia)

El **alcance de este primer informe** corresponde a las Fases 1 y 2 del proyecto: la definición conceptual del problema, la configuración de un entorno reproducible y el desarrollo del pipeline de obtención, exploración, limpieza, transformación y validación del conjunto de datos. El análisis estadístico más profundo, la programación de algoritmos

estructurados/recursivos y la comunicación visual de resultados corresponden a las Fases 3 y 4, que se desarrollarán en las semanas siguientes.

La problemática requiere necesariamente un enfoque basado en programación y análisis de datos. El análisis considera horas de sueño, actividad física, sexo, edad, raza o etnicidad como variables de ajuste

Cada fase del proyecto contribuye de forma acumulativa a responder la pregunta central:

- Fase 1: Define el problema y el entorno;
- Fase 2: Entrega un dataset limpio y validado;
- Fase 3: Aplica programación estructurada y recursiva para profundizar el análisis;
- Fase 4: Entrega los hallazgos mediante visualizaciones y un informe final.

III. Definición de la problemática y objetivos del proyecto

Formulación de la problemática

¿Qué relación existe entre los patrones de uso de tecnología y los indicadores de salud mental autopercebida y horas de sueño en los estudiantes incluidos en el dataset YRBS 2023, considerando variables sociodemográficas y de actividad física?

Esta es la pregunta central que orienta el proyecto, a partir de la cual se desprenden preguntas secundarias que guían el análisis exploratorio y, en fases posteriores, el análisis estadístico.

Preguntas centrales del análisis

- ¿Cuáles son las características sociodemográficas de la muestra y cómo se distribuyen los patrones de uso de tecnología, salud mental autopercebida y calidad del sueño?
- ¿Cuál es el estado de calidad del dataset YRBS 2023 en términos de valores perdidos, atípicos, duplicados e inconsistencias, y qué transformaciones de preprocesamiento se justifican para garantizar su validez analítica?
- ¿Existen patrones de asociación exploratorios observables entre el tiempo de uso de tecnología, la actividad física y la salud mental o el sueño?
- ¿De qué manera el uso conjunto de dispositivos, redes sociales, actividad física y factores sociodemográficos influye en la salud mental autopercebida al ser analizados mediante un modelo de regresión?

Objetivo general

Analizar la relación entre los patrones de uso de tecnología (dispositivos electrónicos y redes sociales) y los indicadores de salud mental autopercebida y horas de sueño en los estudiantes incluidos en el dataset YRBS 2023, controlando por variables sociodemográficas y de actividad física, mediante un flujo de trabajo reproducible y documentado.

Objetivos específicos

- **Caracterizar** la distribución sociodemográfica y los patrones iniciales de uso de tecnología, salud mental y sueño en la muestra, mediante análisis exploratorio descriptivo para establecer la línea de base del estudio.
- **Diagnosticar y preprocesar** el conjunto de datos YRBS 2023 mediante un pipeline modular en Python, identificando y tratando valores faltantes, atípicos e inconsistencias para garantizar la integridad y calidad analítica de la data.
- **Validar** el dataset resultando mediante pruebas de consistencia técnica y verificación estructural con assert, asegurando la exportación de un conjunto limpio a data/processed/ para las fases posteriores.
- **Explorar y evaluar** las asociaciones preliminares entre las variables tecnológicas, de estilo de vida y salud mental, preparando la estructura de datos para el posterior modelamiento estadístico y regresional en las Fases 3 y 4.

Alcance

Este informe cubre exclusivamente las Fases 1 y 2: definición del problema, configuración del entorno reproducible y desarrollo del pipeline de datos (obtención, exploración, limpieza, transformación y validación). El análisis no incluye modelación predictiva avanzada, pruebas de hipótesis formales ni visualizaciones analíticas finales, los cuales se abordarán en las Fases 3 y 4.

Supuestos y restricciones

El proyecto parte del supuesto operativo de que los registros son técnicamente utilizables para practicar procedimientos de ciencia de datos; sin embargo, no se asumirá que representan observaciones clínicas.

- Las variables de salud mental y horas de sueño declaradas por cada persona, se asumen como un reflejo válido de su estado percibido.
- El análisis se restringe a las 11 variables originales del dataset; no se incorporan fuentes externas en esta etapa.
- No se incorporarán variables externas.
- Las relaciones identificadas serán interpretadas como asociaciones y no como causalidad.
- La ausencia de información temporal impide analizar la evolución longitudinal.

Articulación con las fases F1-F4

La problemática y los objetivos definidos en este apartado se desagregan operativamente en el notebook F1_Definicion.ipynb (Fase 1) y en los notebooks F2_01 a F2_03 (Fase 2), que implementan respectivamente la configuración del entorno y el pipeline de datos descritos en las secciones siguientes.

En la Fase 3 se desarrollará la modelación y el análisis algorítmico del conjunto de datos, aplicando programación estructurada y funciones reutilizables para identificar y caracterizar las relaciones entre el uso de redes sociales, las horas de sueño, la actividad física y la salud mental autopercebida.

En la Fase 4 se abordará la comunicación e interpretación de los resultados mediante visualizaciones, síntesis de hallazgos, discusión de limitaciones y elaboración del informe final, permitiendo traducir los resultados técnicos en conclusiones comprensibles y fundamentadas.

IV. Aplicación de herramientas científicas.

El proyecto se trabajó en Python 3.14.7 con pandas 3.0.5 y NumPy 2.5.3 para la carga y revisión de los datos. Jupyter se usó para documentar el análisis y Git/GitHub para registrar los cambios del equipo. Las versiones se verificaron en la sección 6 del notebook S1_F1_Definicion.ipynb.

En fases posteriores se incorporarán librerías estadísticas y de visualización cuando sean requeridas por las preguntas y el análisis.

Reproducibilidad técnica

La problemática requiere un enfoque computacional debido al volumen y variables de distinta naturaleza, incluyendo variables numéricas continuas, discretas y variables categóricas nominales.

El proyecto quedó con un único requirements.txt en la raíz, donde se fijaron las versiones usadas en el notebook de la Fase 1 (pandas 3.0.5, NumPy 2.5.3 e ipykernel). En el commit 5c357f9, del 15 de septiembre, se eliminaron los archivos requirements.txt duplicados que estaban en F1 y F2. En el README se dejaron las instrucciones para crear el entorno virtual .venv, instalar las dependencias y registrar el kernel "Python (grupo8-mcdi500)".

Control de versiones

El trabajo se registró en GitHub. Entre el 13 y el 16 de septiembre de 2026 se hicieron 18 commits, con aportes de los cuatro integrantes. La mayoría de los mensajes siguió la convención de prefijos definida en el README (docs, data y fix). Cinco commits hechos desde la interfaz web de GitHub quedaron con el mensaje por defecto. Se creó una rama secundaria, pero todos los cambios se integraron directamente en main, sin merges ni revisiones previas.

Documentación del proceso

La documentación se hizo en celdas markdown dentro de los notebooks. En el notebook de la Fase 1 se dejaron escritos el contexto del dataset, las preguntas de análisis, los objetivos, el alcance y los supuestos, junto con la verificación del entorno. El registro de

cada transformación (dato original → problema detectado → criterio aplicado → resultado → validación) se aplicará en el notebook de la Fase 2, que al cierre de este informe tiene definida su estructura pero aún no se ejecuta.

```

proyecto-grupo8-mcdi500/
├── src/
│   └── procesamiento.py           funciones: carga, selección, diagnóstico,
│                                   clasificación, transformación, validación
├── F1/
│   ├── data/raw/
│   │   └── XXH2023_YRBSS_data.csv    dataset original YRBS 2023 (CDC)
│   └── notebooks/
│       └── S1_F1_Definicion.ipynb    Fase 1 – definición problema y
│                                       entorno
├── F2/
│   ├── data/processed/             salida del pipeline (entrada de F3)
│   └── notebooks/
│       └── S1_F2_Preprocesamiento.ipynb Fase 2 – obtención, limpieza y
│                                       transformación
├── F3/
│   └── notebooks/
│       └── Fase 3.md                 (pendiente: notebook de Fase 3)
├── F4/
│   └── notebooks/
│       └── Fase 4.md                 (pendiente: notebook de Fase 4)
├── docs/
│   ├── bitacora_decisiones.md       registro de decisiones técnicas
│   ├── diccionario_variables.md     diccionario de variables data set
│   ├── Informe/
│   └── Mapa Conceptual Proyecto/
├── .gitignore
├── requirements.txt                 dependencias del proyecto (único, en la raíz)
└── README.md

```

V. Diseño de soluciones algorítmicas eficientes.

A. Codificación funcional

En la Fase 1 se definió el diseño del pipeline como una secuencia de funciones con parámetros explícitos (carga, diagnóstico, transformación y validación), coordinadas por una función principal. Este diseño se implementa en el notebook de la Fase 2. En la Fase 1 el código se limitó a verificar el entorno y cargar el dataset con pandas, lo que confirmó 20.103 filas y 117 columnas. De esta forma, cada componente se prueba individualmente y para utilizarse dentro de una función coordinadora.

Por ejemplo: `def ejecutar_pipeline(ruta)`

```
import sys
sys.path.append('.././src')
from procesamiento import cargar_datos

RUTA = '.././F2/data/raw/XXH2023_YRBSS_data.csv'
df = cargar_datos(RUTA)

print('Filas, columnas:', df.shape)
df.head()
```

B. Preprocesamiento y transformación del dataset

En la revisión inicial de la Fase 1 en el dataset se verifica la estructura, compuesta por 20.103 registros y 11 variables, confirmando que el código base del entorno reproducible está funcionando. Siguiendo a esto, en la Fase 2 se revisan tipos de datos, identificadores duplicados, valores faltantes y códigos fuera de los dominios definidos. Las variables de edad, sexo, raza o etnicidad, salud mental, uso de redes sociales, sueño y actividad física se mantuvieron con sus códigos originales para preservar la trazabilidad, dejando recodificaciones o variables derivadas para los análisis posteriores.

Todas las transformaciones quedan documentadas para aplicarse sobre una copia procesada, manteniendo inalterado el archivo original.

C. Validación técnica y verificación del código.

Se definieron tres niveles de prueba para validar el pipeline en la Fase 2:

- Casos normales: dataset completo con estructura esperada.
- Casos límite: data frame vacío, columnas con valores extremos o categorías inesperadas.
- Excepciones: archivo inexistente, columna obligatoria ausente o tipo incompatible.

A la fecha de este informe estas pruebas no se han ejecutado. En la Fase 1 la verificación consistió en correr el notebook dentro del entorno y confirmar las versiones de Python, pandas y NumPy, además de la carga completa del dataset.

Notebook *F1_Definición.ipynb* (F1)

En el cuaderno se detalla la información explicada anteriormente referente al contexto y formulación, preguntas de análisis, objetivo general y específicos; y alcance, restricciones y supuestos. Siguiendo a esto se indica la configuración y verificación del entorno, y el reconocimiento inicial del conjunto de datos:

▼ 6. Configuración y verificación del entorno

Código base que evidencia que el entorno reproducible está funcionando.

```
[1]: import sys
      print('Python:', sys.version)

      # Verificar librerías clave del entorno
      import pandas as pd
      import numpy as np
      print('pandas:', pd.__version__)
      print('numpy:', np.__version__)
```

```
Python: 3.14.7 | packaged by Anaconda, Inc. | (main, Aug 14 2026, 10:12:46) [MSC v.1942 64 bit (AMD64)]
pandas: 3.0.5
numpy: 2.5.3
```

7. Reconocimiento inicial del conjunto de datos

Solo carga y una mirada superficial — sin limpiar ni transformar (eso es F2).

```
[2]: from pathlib import Path

RUTA = Path('../data/raw/XXH2023_YRBSS_data.csv') # completar: ruta al archivo del dataset
dtypes_problematizantes = {
    'q6orig': str,
    'q7orig': str,
    'q5': str
}

df = pd.read_csv(RUTA, dtype=dtypes_problematizantes)

print('Filas, columnas:', df.shape)
df.head()
```

Filas, columnas: (20103, 117)

```
[2]:
```

	site	raceeth	q6orig	q7orig	record	orig_rec	q1	q2	q3	q4	...	q102	q103	q104	q105	q106	q107	BMIPCT	weight	stratum	psu
0	XX	NaN	505	180	1	NaN	3.0	1.0	1.0	NaN	...	2.0	3.0	3.0	2.0	2.0	2.0	97.083855	0.8614	103	16294
1	XX	5.0	N N	233	2	NaN	4.0	2.0	1.0	2.0	...	2.0	2.0	5.0	2.0	1.0	2.0	NaN	0.8920	103	16294
2	XX	5.0	506	165	3	NaN	5.0	2.0	3.0	2.0	...	1.0	2.0	4.0	2.0	2.0	1.0	92.262516	0.5081	103	16294
3	XX	5.0	N N	105	4	NaN	6.0	1.0	2.0	2.0	...	2.0	4.0	5.0	2.0	1.0	1.0	NaN	1.1759	103	16294
4	XX	5.0	601	125	5	NaN	3.0	2.0	1.0	2.0	...	2.0	2.0	5.0	2.0	2.0	1.0	7.567053	0.8920	103	16294

5 rows × 117 columns

Notebooks Ejecutables (F2)

En el cuaderno se detalla la información explicada anteriormente referente a la selección, transformación y validación en el conjunto de datos en base a la pregunta de investigación, detallando además hallazgos de calidad, selección de columnas con información relevante en base a las preguntas y objetivos, diagnóstico de variables faltantes y/o nulas, clasificación y transformación, validación y finalmente el almacenamiento del conjunto de datos procesado.

S1_F2_Preprocesamiento — Selección, transformación y validación

Dataset: 2023 Youth Risk Behavior Survey (YRBS), CDC — national (site=XX), 20,103 registros, 117 columnas originales.

Pregunta de investigación: ¿Qué relación existe entre los patrones de uso de tecnología y los indicadores de salud mental autopercebida y horas de sueño en los estudiantes incluidos en el dataset YRBS 2023, considerando variables sociodemográficas y de actividad física?

Fuente: Centers for Disease Control and Prevention (CDC). (2024). 2023 Youth Risk Behavior Survey Data [conjunto de datos]. <https://www.cdc.gov/yrbbs/data/index.html>

```
In [1]: import sys
from pathlib import Path

# Agrega src/ de la raíz del proyecto al path
sys.path.append(str(Path('.') / '..' / 'src'))

import pandas as pd
from procesamiento import (
    cargar_datos, seleccionar_columnas, diagnosticar_datos,
    clasificar_variables, transformar_datos, validar_datos,
    guardar_dataset, COLUMNAS_ANALISIS, COLUMNAS_SIN_DEPENDENCIA,
    ESCALAS_ORDINALES,
)

# Ruta relativa al notebook: F2/notebooks/ -> F1/data/raw/
RUTA_RAW = Path('.') / '..' / 'F1' / 'data' / 'raw' / 'XXH2023_YRBSS_data.csv'
df = cargar_datos(str(RUTA_RAW))
print('Dimensiones del archivo original:', df.shape)
```

Dimensiones del archivo original: (20103, 117)

1. Hallazgo de calidad: dtype mixto en q6orig

q6orig mezcla texto (p. ej. "N N") con códigos numéricos, lo que generaba un `DtypeWarning` al inferir el tipo automáticamente. Se resolvió declarando `dtype={'q6orig': 'string'}` en `cargar_datos`. No se descarta la columna: se documenta como un hallazgo de calidad real del archivo original.

```
In [2]: print(df['q6orig'].dtype)
df['q6orig'].value_counts(dropna=False).head(10)
```

```
string
Out[2]: q6orig
504    1686
506    1684
507    1633
505    1589
503    1552
508    1540
510    1365
509    1334
502    1256
511    1111
Name: count, dtype: int64[pyarrow]
```

2. orig_rec: columna 100% vacía

El validador genérico señaló `orig_rec` con más de 60% de nulos. En este dataset está vacía al 100%: se elimina.

```
In [3]: print('orig_rec: % nulos =', df['orig_rec'].isna().mean() * 100)
df = df.drop(columns=['orig_rec'])
print('Columnas tras eliminar orig_rec:', df.shape[1])
```

```
orig_rec: % nulos = 100.0
Columnas tras eliminar orig_rec: 116
```

3. Selección de columnas por código (desde el archivo original)

Con 117 columnas no es posible avanzar sin acotar. Se seleccionan, por código, únicamente las variables necesarias para responder la pregunta de investigación, declaradas explícitamente en `COLUMNAS_ANALISIS` (módulo `src/procesamiento.py`), con su código YRBS y su significado según el codebook oficial 2023.

```
In [4]: for col_original, col_nueva in COLUMNAS_ANALISIS.items():
        print(f'{col_original}>10} -> {col_nueva}')
```

```
record -> id_registro
weight -> peso_muestral
stratum -> estrato
psu -> psu
q1 -> edad_cod
q2 -> sexo_cod
raceeth -> raceeth_cod
q84 -> salud_mental_cod
q80 -> redes_sociales_cod
q85 -> sueno_cod
q76 -> actividad_fisica_cod
```

```
In [5]: df_sel = seleccionar_columnas(df)
print('Dimensiones tras selección:', df_sel.shape)
df_sel.head()
```

Dimensiones tras selección: (20103, 11)

```
Out[5]:
```

	id_registro	peso_muestral	estrato	psu	edad_cod	sexo_cod	raceeth_cod	salud_mental_cod	redes_sociales_cod	sueno_cod	actividad_fisica_cod
0	1	0.8614	103	16294	3.0	1.0	NaN	1.0	6.0	3.0	1.0
1	2	0.8920	103	16294	4.0	2.0	5.0	3.0	4.0	5.0	5.0
2	3	0.5081	103	16294	5.0	2.0	5.0	2.0	8.0	1.0	8.0
3	4	1.1759	103	16294	6.0	1.0	5.0	3.0	8.0	4.0	3.0
4	5	0.8920	103	16294	3.0	2.0	5.0	3.0	6.0	3.0	8.0

4. Diagnóstico de faltantes en las variables seleccionadas

Las 7 variables de análisis (q1, q2, raceeth, q76, q80, q84, q85) **no tienen dependencia de otra pregunta** en el Apéndice C del codebook oficial (a diferencia, por ejemplo, de Q34 que depende de haber fumado en Q33). Esto significa que, para este subconjunto, un valor nulo es **no responde genuino** (el estudiante vio la pregunta y la dejó en blanco), no "no aplica" estructural por salto de pregunta.

```
In [6]: diagnostico = diagnosticar_datos(df_sel)
        for k, v in diagnostico.items():
            print(f'{k}: {v}')

n_filas: 20103
n_columnas: 11
pct_nulos_por_columna: {'id_registro': np.float64(0.0), 'peso_muestral': np.float64(0.0), 'estrato': np.float64(0.0), 'psu': np.float64(0.0), 'edad_cod': np.float64(0.5), 'sexo_cod': np.float64(0.8), 'raceeth_cod': np.float64(1.8), 'salud_mental_cod': np.float64(21.9), 'redes_sociales_cod': np.float64(24.4), 'sueno_cod': np.float64(13.2), 'actividad_fisica_cod': np.float64(6.1)}
duplicados_totales: 0
tipos_de_datos: {'id_registro': 'int64', 'peso_muestral': 'float64', 'estrato': 'int64', 'psu': 'int64', 'edad_cod': 'float64', 'sexo_cod': 'float64', 'raceeth_cod': 'float64', 'salud_mental_cod': 'float64', 'redes_sociales_cod': 'float64', 'sueno_cod': 'float64', 'actividad_fisica_cod': 'float64'}
```

5. Clasificación de variables: ordinal, no numérica

El validador genérico del curso clasificaría q80, q84, etc. como "discreta" por ser códigos enteros 1-8. Esa clasificación es incorrecta para este análisis: son escalas ordinales de frecuencia (p. ej. Q84: Never < Rarely < Sometimes < Most of the time < Always), y tratarlas como numéricas asumiría que la distancia entre "rara vez" y "a veces" es igual a la distancia entre "a veces" y "siempre", lo cual no está garantizado por el diseño de la escala.

```
In [7]: clasificacion = clasificar_variables(df_sel)
        for col, info in clasificacion.items():
            print(f'{col:22} -> {info["rol_equipo"]}')

id_registro          -> identificador
peso_muestral        -> muestral (weight)
estrato              -> muestral (stratum)
psu                  -> muestral (psu)
sexo_cod             -> nominal
raceeth_cod          -> nominal
edad_cod             -> ordinal
actividad_fisica_cod -> ordinal
redes_sociales_cod   -> ordinal
salud_mental_cod     -> ordinal
sueno_cod            -> ordinal
```

6. Transformación: tipado categórico ordenado

```
In [8]: df_t = transformar_datos(df_sel)
        df_t.dtypes
```

```
Out[8]: id_registro          int64
        peso_muestral        float64
        estrato              int64
        psu                  int64
        edad_cod             category
        sexo_cod             float64
        raceeth_cod          float64
        salud_mental_cod     category
        redes_sociales_cod   category
        sueno_cod            category
        actividad_fisica_cod category
        dtype: object
```

7. Decisión sobre ponderación (weight, stratum, psu)

Este dataset tiene diseño muestral complejo. **Decisión del equipo para las Fases 1-2: no se pondera.** Ponderar correctamente exige software de análisis de encuestas complejas (varianza por conglomerados), fuera del alcance de esta etapa. En consecuencia, **todo resultado descriptivo de este proyecto describe la muestra de 20.103 estudiantes encuestados en 2023, y no se generaliza a la población de estudiantes de EE. UU.** Las columnas peso_muestral, estrato y psu se conservan en el dataset procesado para un eventual análisis ponderado en fases posteriores.

8. Validación

```
In [9]: resultado = validar_datos(df_t)
        for k, v in resultado.items():
            print(f'{k}: {v}')
```

```
columnas_obligatorias_presentes: True
id_registro_unico: True
sin_duplicados: True
edad_cod_en_rango: True
redes_sociales_cod_en_rango: True
salud_mental_cod_en_rango: True
sueno_cod_en_rango: True
actividad_fisica_cod_en_rango: True
validacion_global: True
```

9. Guardado del dataset procesado

```
In [10]: # Salida del pipeline: entrada directa de La Fase 3
        RUTA_SALIDA = Path('.') / 'data' / 'processed' / 'yrbs2023_seleccion_procesada.csv'
        ruta_salida = guardar_dataset(df_t, str(RUTA_SALIDA))
        print('Guardado en:', ruta_salida)
```

Guardado en: /Users/betosanchez/Desktop/Magister Data Science & IA /proyecto-grupo8-mcdi500/F2/data/processed/yrbs2023_seleccion_procesada.csv

Conclusión

El dataset se redujo de 117 a 11 columnas relevantes para la pregunta de investigación, seleccionadas por código y documentadas con su fuente en el codebook oficial. Se corrigió el hallazgo de calidad en `q6orig`, se eliminó `orig_rec` (vacía), se clasificaron las variables como ordinales (no numéricas), y se documentó la decisión de no ponderar junto con la limitación que eso implica. El dataset queda listo para el análisis de asociación en la Fase 3.

Vinculación del mapa conceptual con el avance de proyecto.

La siguiente matriz vincula explícitamente cada bloque del mapa conceptual técnico elaborado en la actividad formativa de la Fase 1 con su materialización concreta en el repositorio, los notebooks, el README y este informe.

Elementos	Implementación en el proyecto	Evidencia verificable	Estado actual
1. Problema y preguntas	Definición del contexto, pregunta principal, objetivos y criterios de éxito del proyecto.	Celdas narrativas del notebook de la Fase 1, README e informe, particularmente en las secciones de definición del problema y objetivos.	Implementado
2. Datos	Selección e incorporación del 2023 National YRBS (CDC), 20.103 registros y 117 variables originales, de las cuales se seleccionan 11 por código. Se considera su almacenamiento como dato original y su posterior procesamiento.	Dataset original en F2/data/raw/XXH2023_YRBSS_data.csv; descripción de variables y codebook oficial referenciado en el notebook y en el informe. Los datos procesados se almacenan en F2/data/processed/.	Implementado
3. Entorno y análisis reproducible	Uso de Python, Jupyter Notebook y un entorno virtual .venv. Las librerías y dependencias necesarias para ejecutar el proyecto se registran en requirements.txt.	Entorno local configurado, notebooks ejecutables, archivo requirements.txt y celdas de importación y verificación de librerías.	Implementado

4. Control de versiones con Git	Uso de un repositorio local para registrar cambios mediante commits pequeños, frecuentes y descriptivos.	Historial de commits del repositorio, identificación de autores, fechas y cambios efectuados en los archivos del proyecto.	Implementado
5. GitHub y colaboración	Uso de un repositorio remoto compartido para respaldar, sincronizar e integrar el trabajo del equipo.	Repositorio grupal en GitHub, historial de contribuciones, sincronización de cambios y acceso colaborativo de los integrantes. El uso de ramas, Pull Requests y revisiones se aplicará según evolucione el desarrollo.	Implementado
6. Documentación científica en notebooks	Integración de código reproducible, narrativa explicativa, visualizaciones, referencias y resultados dentro de los notebooks.	Archivos .ipynb, celdas Markdown, comentarios de código, README, referencias incorporadas y secciones de resultados y conclusiones.	Implementado
7. Estructura actual del repositorio	Organización del proyecto mediante las carpetas F1/notebooks/ y F2/ (con datos y notebook de cada fase), F3/ y F4/ (pendientes), src/ (procesamiento.py), docs/ (mapa, informe, bitácora, validador) y Validar_DataSet.ipynb en la raíz, junto con requirements.txt y .gitignore.	Árbol de carpetas del repositorio real (verificable en GitHub), coincidente con el declarado en el README.	Implementado


8. Ejemplos de commits	Convención de prefijos (docs, data, feat, fix, test) definida en el README y aplicada en los commits reales del repositorio.	Ejemplos reales del historial: “docs: agrega mapa conceptual v1 y v2”; “data: incorpora dataset mental_health_and_technology_usage_2024.csv”; “feat: implementa funciones de preprocesamiento”; “fix: elimina requirements.txt duplicados en F1 y F2”.	Implementado
Limpieza, transformación y validación	Selección de 11 columnas por código, corrección del dtype de q6orig, eliminación de orig_rec, clasificación de variables ordinales y validación de columnas obligatorias, unicidad y rangos.	Notebook S1_F2_Preprocesamiento.ipynb ejecutado sin errores; dataset procesado en F2/data/processed/yrbs2023_seleccion_procesada.csv; resultado de Validar_DataSet.ipynb en docs/informe_dataset_validator.md.	En desarrollo
Modelación y análisis algorítmico	Aplicación de técnicas de programación y análisis orientadas a identificar relaciones entre el uso de tecnología y los indicadores de salud mental, estrés y calidad del sueño.	Código, funciones reutilizables, resultados analíticos y notebooks correspondientes a la Fase 3.	Proyectado
Comunicación final de resultados	Elaboración de visualizaciones interpretables, síntesis de hallazgos, conclusiones, limitaciones y recomendaciones.	Notebooks finales, visualizaciones, informe consolidado, README actualizado y productos de comunicación correspondientes a la Fase 4.	Proyectado

Los bloques 1 a 8 del mapa conceptual quedaron materializados en el avance de las fases 1 y 2. La modelación y la comunicación visual de resultados, proyectadas en el mapa como trabajo de fases posteriores, se abordarán en las Fases 3 y 4 respectivamente, manteniendo coherencia entre la planificación conceptual y el desarrollo técnico real del proyecto. El mapa conceptual utilizado para la planificación inicial se presenta en el **Anexo 1**, con el fin de contrastar la estructura conceptual propuesta con el avance efectivo alcanzado en cada fase del proyecto.

Referencias

- Centers for Disease Control and Prevention. (2024). *2023 National Youth Risk Behavior Survey Data* [Conjunto de datos]. <https://www.cdc.gov/yrbs/data/index.html>
- Centers for Disease Control and Prevention. (2024). *2023 YRBS Data User's Guide* [Manual técnico y codebook].
<https://www.cdc.gov/yrbs/media/pdf/2023/2023-YRBS-SADC-Documentation.pdf>
- Chacon, S., & Straub, B. (2014). *Pro Git* (2nd ed.). Apress. <https://git-scm.com/book>
- NumPy Developers. (2025). *NumPy documentation*. <https://numpy.org/doc/stable/>
- The pandas development team. (2024). *pandas documentation* (Version 3.0.5) [Documentación técnica oficial]. <https://pandas.pydata.org/docs/>
- Universidad Andrés Bello, Facultad de Ingeniería. (2026a). *Guía de Git y GitHub*. Documento técnico de apoyo, MCDI500 Programación para la Ciencia de Datos, Magíster en Ciencia de Datos e Inteligencia Artificial.
- Universidad Andrés Bello, Facultad de Ingeniería. (2026b). *Sumativa 1: Avance del proyecto, Fases 1 y 2* [Pauta de evaluación]. MCDI500 Programación para la Ciencia de Datos.
- Valkenburg, P. M., Meier, A., & Beyens, I. (2022). *Social media use and its impact on adolescent mental health: An umbrella review of the evidence*. *Current Opinion in Psychology*, 44, 58–68. <https://doi.org/10.1016/j.copsyc.2021.08.017>
- Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>

Anexos



Anexo 1: Mapa conceptual v4 del proyecto — análisis del YRBS 2023

Enlace al repositorio en github:

<https://github.com/MatiasIMO98/proyecto-grupo8-mcdi500>