

Informe Final, MCDI500 PROGRAMACIÓN PARA LA CIENCIA DE DATOS

Proyecto final integrador Fase 4: análisis, reproducibilidad y comunicación de resultados

Proyecto: uso de redes sociales y salud mental autopercebida en adolescentes (YRBS 2023) ·

Grupo 8

Docente: Dr. Omar Salinas Silva

Estudiantes: Matías Manriquez Ortiz, Daniel Pérez Ramirez, Abigail Robles Chávez, Roberto Sánchez Saldivia.

Repositorio GitHub: <https://github.com/MatiasManriquezO/proyecto-grupo8-mcdi500>

Magíster en Ciencia de Datos e Inteligencia Artificial

Universidad Andrés Bello, Santiago.

Santiago, 04 de octubre de 2026.

I. índice

I. Índice	2
II. Introducción y contextualización	3
III. Definición de la problemática y objetivos del proyecto	3
IV. Aplicación de herramientas científicas	4
V. Reproducibilidad técnica	4
VI. Control de versiones	4
VII. Documentación del proceso	4
VIII. Repositorio GitHub actualizado	4
IX. Diseño de soluciones algorítmicas eficientes	4
A. Codificación funcional	4
B. Preprocesamiento y transformación del dataset	5
C. Validación técnica y verificación del código	5
D. Eficiencia y optimización	5
E. Diseño estructurado del código	5
F. Notebook final ejecutado y documentado	5
X. Implementación de código modular y robusto	6
A. Programación orientada a objetos	6
B. Documentación de arquitectura	6
XI. Construcción de visualizaciones de datos efectivas	6
A. Preprocesamiento y transformación de datos	6
B. Visualizaciones analíticas	6
XII. Metodología del desarrollo técnico	8
XIII. Validación y reflexión técnica	8
XIV. Resultados	8
XV. Discusión	8
XVI. Conclusiones	8
XVII. Trazabilidad de mejoras	9
XVIII. Presentación audiovisual	9
XIX. Referencias	9

II. Introducción y contextualización

La adolescencia concentra el inicio de muchos problemas de salud mental y coincide con el uso más intensivo de redes sociales (Valkenburg et al., 2022). En 2023, el 28,5 % de los estudiantes de enseñanza media de Estados Unidos reportó salud mental no buena (Verlenden et al., 2024) y el 77,0 % usaba redes varias veces al día (Young et al., 2024). **Relevancia:** saber dónde se concentra el malestar permite focalizar la prevención.

El proyecto usa el *Youth Risk Behavior Survey 2023* (YRBS), encuesta del CDC con 20.103 estudiantes y 117 variables (Centers for Disease Control and Prevention [CDC], 2024a). Su diseño muestral complejo y su no respuesta (hasta 24,4 %) exigen programación. El **propósito** es estimar esa relación de forma representativa y reproducible: F1 definió el problema; F2 construyó el pipeline; F3 lo llevó a clases; y F4 pondera, valida contra el CDC y comunica los resultados. El entregable central es F4/notebooks/S3_F4_Integracion_Resultados_Grupo8.ipynb.

III. Definición de la problemática y objetivos del proyecto

Problema. Medir cuánto cambia la proporción de estudiantes con salud mental no buena (q84) según la frecuencia de uso de redes (q80), si difiere por sexo, si se acompaña de menos sueño (q85) y si persiste al ajustar. **Pregunta central (F1):** ¿qué relación existe entre el uso de tecnología y la salud mental autopercebida y el sueño, considerando variables sociodemográficas y de actividad física?

Objetivo general: analizar esa relación con estimaciones representativas y un flujo reproducible (Tabla 1).

Tabla 1. *Objetivos específicos, hipótesis y evidencia que los responde*

Objetivo específico	Hipótesis
OE1. Estimar la proporción con salud mental no buena según la frecuencia de uso	H1: aumenta con el uso
OE2. Determinar si la relación difiere entre sexos	H2: es mayor en el sexo femenino
OE3. Describir la proporción que duerme 8 h o más según el uso	H3: disminuye con el uso
OE4. Estimar la asociación ajustada por sexo, edad, raza/etnicidad, sueño y actividad	H4: se mantiene al ajustar
OE5. Sostenerlo con un flujo reproducible, validado y medido	—

Nota. Las hipótesis derivan de Valkenburg et al. (2022), Young et al. (2024) y del hallazgo muestral de F3. OE1 y OE4 refinan los objetivos 1 y 4 de F1.

Alcance: estimaciones poblacionales con intervalos de confianza y un modelo ajustado; **no aborda** causalidad ni imputación. **Restricciones:** encuesta transversal; q80 mide frecuencia, no horas ni tipo de uso. **Supuestos:** las respuestas son autopercepción y los pesos del CDC corrigen la no respuesta

(CDC, 2024b).

IV. Aplicación de herramientas científicas

pandas lee los datos y construye cada tabla; **NumPy** hace los cálculos vectorizados (`np.bincount`); **SciPy** aporta el cuantil t ; **Matplotlib** y **seaborn** dibujan las figuras; **timeit** mide (Python Software Foundation, s. f.); **pytest** automatiza las pruebas; y **Jupyter** con **Git/GitHub** integran código e historial.

V. Reproducibilidad técnica

Un único `requirements.txt` fija las versiones y el notebook compara la versión fijada e instalada. `ejecutar_notebooks` copia el repositorio a una carpeta temporal y ejecuta F1, F2 y F3 sin errores (`verificacion_ejecucion_f4.csv`).

VI. Control de versiones

`.mailmap` unifica las identidades de los cuatro integrantes. El commit `f809a58` eliminó siete módulos por error y se restauraron en `a37fd64`. La Fase 4 se integró en `main` con commits por componente, cada uno enlazado y justificado en `changelog.md`.

VII. Documentación del proceso

`docs/bitacora_decisiones.md` registra cada decisión con la cifra que la respalda; `docs/adr/` guarda cinco decisiones de arquitectura; y `changelog.md` se genera desde git log.

VIII. Repositorio GitHub actualizado

El repositorio tiene una carpeta por fase (F1–F4), `tests/`, `docs/` y un README con ejecución, dependencias, estructura y aporte de cada integrante.

IX. Diseño de soluciones algorítmicas eficientes

A. Codificación funcional

Cada tarea es una función o clase con parámetros explícitos:

```
diseno = DisenoMuestral(datos) # pesos, 16 estratos, 89 conglomerados
prev = PrevalenciaPonderada(diseno, nivel=0.95)
por_redes = prev.estimar(datos, "salud_mental_mala", por="redes_sociales_cod")
modelo = RegresionLogisticaPonderada(diseno).estimar(datos, "salud_mental_mala", X=X)
```

`DisenoMuestral` define el conglomerado como el par estrato-PSU. La varianza de la proporción

se obtiene por **linealización de Taylor** (Lumley, 2010) y los intervalos se calculan en escala logit con t de 73 grados de libertad.

B. Preprocesamiento y transformación del dataset

El pipeline de F2 (12 pasos) lleva el archivo del CDC de 20.103×117 a 20.103×26 : selecciona 11 columnas, convierte códigos a Int64 y escalas a categorías ordenadas, y deriva los indicadores 0/1. **No se imputa** (rellenar q84 inventaba 4.398 respuestas, ADR-0001) **ni se escala** (una ordinal no tiene distancias iguales). El notebook verifica que el pipeline reproduce el CSV de F2 carácter por carácter.

C. Validación técnica y verificación del código

Validación externa: el estimador reproduce al decimal las seis prevalencias y seis intervalos del CDC (validacion_externa_cdc_f4.csv). **Pruebas:** 36 pruebas pytest cubren casos normales, límite, excepciones y regresión de F1–F3. **Verificación cruzada:** los coeficientes difieren en $3 \cdot 10^{-15}$ de los de statsmodels.

D. Eficiencia y optimización

Las tres implementaciones de la varianza por diseño se midieron con timeit, tras verificar que dan el mismo resultado, y a seis tamaños para estimar el **orden empírico** (Tabla 2).

Tabla 2. Varianza por diseño con 20.103 filas, medida con timeit

Implementación	Tiempo (ms)	Veces más lenta	Memoria pico (KiB)	Pendiente (n grande)
np.bincount (adoptada)	0,084	1,0	5,0	0,98
groupby de pandas	1,090	13,0	836,2	0,50
Bucle de Python	3,244	38,8	6,8	1,02

Nota. Fuente: F4/resultados/eficiencia_varianza_f4.csv, orden_empirico_f4.csv y puntos_de_cruce_f4.csv.

Las tres son $O(n)$ y difieren por la constante. Se adoptó bincount: gana en todos los tamaños, usa $O(G \cdot k)$ de memoria ($G = 89$) y acepta la matriz del modelo (ADR-0002).

E. Diseño estructurado del código

Cada módulo tiene una responsabilidad: encuesta.py estima, rendimiento.py mide, visualizacion.py dibuja y verificacion.py comprueba. Bajo acoplamiento: cambiar la estrategia de faltantes modifica **un** archivo. La recursión se usa solo en el árbol de segmentos de F3 (1ru_cache)

F. Notebook final ejecutado y documentado

El notebook de F4 (64 celdas, 32 de código) corre completo con numeración continua e integra

F1–F4 con markdown antes de cada bloque. Cierra con una verificación automática (11 de 11 comprobaciones, 5 de 5 objetivos con su evidencia) y con la **respuesta a la pregunta de investigación** (sección 15), y guarda en F4/resultados/ los 21 archivos que respaldan este informe.

X. Implementación de código modular y robusto

A. Programación orientada a objetos

EstimadorEncuesta es una clase base abstracta con el contrato `estimar()`; PrevalenciaPonderada y RegresionLogisticaPonderada lo implementan de forma distinta (**polimorfismo**) y **encapsulan** el diseño. `ArbolPrevalenciaPonderada` **hereda** de `ArbolPrevalencia` (F3) y solo redefine `estadisticas()`: la ponderación se agregó sin modificar F3 (ADR-0004).

B. Documentación de arquitectura

`docs/arquitectura.md` sigue la infografía del curso (Universidad Andrés Bello [UNAB], 2026c) con cuatro diagramas. Cada patrón responde a un problema: **Strategy**, cambiar el tratamiento de faltantes con un argumento; **Factory**, armar los 12 pasos sin repetir constantes; **Observer**, registrar cada paso sin mezclarlo con la transformación.

XI. Construcción de visualizaciones de datos efectivas

A. Preprocesamiento y transformación de datos

El conjunto para modelar no sirve para graficar (UNAB, 2026a): su matriz tiene 19 columnas 0/1. Las figuras usan una **copia interpretable**, `tabla_visual.csv`, con una fila por nivel de uso. **Limpieza**: solo estudiantes con respuesta en las dos variables de cada figura, sin imputar. **Transformaciones**: códigos a etiquetas del codebook, orden ordinal declarado y conteos a porcentaje ponderado con su intervalo. **Normalización**: no se escala, los porcentajes ya comparten la escala 0–100.

Tabla 3. Conjunto listo para visualizar (dos de sus ocho filas)

uso redes	n	pct ponderado	ic inf	ic sup	pct muestral
No usa	784	15,5	11,8	20,1	20,3
Más de una vez por hora	3.682	33,1	30,7	35,6	35,3


Nota. Fuente: F4/resultados/tabla_visual_f4.csv.

B. Visualizaciones analíticas

Las tres figuras responden OE1–OE3 en tres actos: contexto, contraste y resolución.

Figura 1. Salud mental no buena según la frecuencia de uso de redes (OE1, contexto) Sube de 15,5 % a 33,1 % (H1 se sostiene).

La salud mental no buena se duplica entre quienes no usan redes y quienes las usan cada hora
 Porcentaje con salud mental no buena la mayor parte del tiempo o siempre (q84 = 4-5), por frecuencia de uso




Fuente: elaboración propia con YRBS 2023 (CDC, 2024). Estimación con pesos, estratos y conglomerados; IC 95 % en escala logit; n = estudiantes con q80 y q84 respondidas.

Nota. Ponderada con IC 95 % (puntos llenos) y muestral (círculos grises). Fuente: F4/resultados/prevalencia_redes_f4.csv.

Figura 2. Salud mental no buena por uso de redes y sexo (OE2, contraste) Mayor proporción en el sexo femenino (20,9% a 44,1%)(H2 se sostiene).

Con más uso de redes, la salud mental no buena sube 23 puntos en mujeres y 7 en hombres
 Porcentaje ponderado con salud mental no buena por uso de redes y sexo (q2); banda = IC 95 %




Fuente: elaboración propia con YRBS 2023 (CDC, 2024). n = estudiantes de ambos sexos con q80 y q84 respondidas.

Nota. Ponderada; la banda es el IC 95 %. Fuente: F4/resultados/prevalencia_redes_sexo_f4.csv.

Figura 3. Estudiantes que duermen 8 horas o más según la frecuencia de uso (OE3, resolución) Solo el 23,2% duerme 8hrs o más (H3 no es concluyente)

En todos los niveles de uso de redes, menos de un tercio duerme 8 horas o más
 Porcentaje ponderado que duerme 8 horas o más en una noche escolar (q85 = 5-7); barras de error = IC 95 %



Fuente: elaboración propia con YRBS 2023 (CDC, 2024). n = estudiantes con q80 y q85 respondidas.

Nota. Ponderada con IC 95 %. Fuente: F4/resultados/sueno_redes_f4.csv.

XII. Metodología del desarrollo técnico

Cada fase entregó un insumo verificable a la siguiente. Se eligió programación **estructurada** para el pipeline, **recursiva** solo con profundidad desconocida y **orientada a objetos** para componentes con estado. Se ponderó por diseño porque la muestra sobrerrepresenta el malestar (30,6 % frente a 28,5 %) y se eligió bincount por las mediciones; en F3 ya se había medido que `apply(axis=1)` no vectoriza.

XIII. Validación y reflexión técnica

Tabla 4. Comparación con la fase anterior

Aspecto	Fase 3	Fase 4 y por qué cambió
Alcance de las cifras	Muestra, sin ponderar	Población: el YRBS tiene diseño muestral complejo
No usa → más de una vez por hora	20,3 % → 35,3 %	15,5 % → 33,1 % con IC 95 %
Validación	Pipeline = CSV de F2	+ cifras del CDC y 36 pruebas: un commit borró módulos
Medición	<code>perf_counter</code> y <code>tracemalloc</code>	+ <code>timeit</code> , orden empírico y punto de cruce

Reflexión del grupo: la notación O no basta (tres versiones lineales difieren hasta 39 veces); un árbol ponderado profundo exigiría precalcular totales; y la herencia extendió F3 sin tocarlo.

XIV. Resultados

Tres hallazgos responden la pregunta central. **Primero**, la salud mental no buena se duplica con el uso: de 15,5 % a 33,1 % (Figura 1). **Segundo**, el aumento se concentra en el sexo femenino: +23,2 pp frente a +7,5 pp (Figura 2). **Tercero**, la asociación no se explica por el sueño (Figura 3) y persiste al ajustar por sexo, edad, raza/etnicidad, sueño y actividad (Tabla 4; 10.941 casos): OR 2,45 con uso de más de una vez por hora. **H4 se sostiene.**

Tabla 5. Odds ratios ajustados de salud mental no buena (selección)

Término (referencia)	OR	IC 95 %	Valor p
Redes: varias veces al día (no usa)	2,03	1,28–3,21	0,003
Redes: más de una vez por hora (no usa)	2,45	1,55–3,85	< 0,001
Sexo femenino (masculino)	2,51	2,15–2,93	< 0,001
Duerme 8 h o más (menos de 8 h)	0,48	0,40–0,58	< 0,001

XV. Discusión

Se sostienen H1, H2 y H4, y H3 queda abierta, en línea con Young et al. (2024) y Valkenburg et al. (2022). **Limitaciones:** diseño transversal; q80 mide frecuencia y no tipo de uso; no respuesta posiblemente no aleatoria. **Riesgo:** leer los odds ratios como riesgos relativos.

XVI. Conclusiones

La salud mental no buena se duplica con el uso horario de redes, la asociación es mayor en el

sexo femenino y persiste al ajustar; el flujo reprodujo las cifras oficiales al decimal. Se recomienda focalizar la prevención en estudiantes de sexo femenino con uso horario y sumar anteriores YRBS.

XVII. Trazabilidad de mejoras

Tabla 6. Observaciones formativas y acciones de mejora

Observación recibida	Acción aplicada	Evidencia
S1: requirements.txt vacío	Versiones fijas, comparadas en el notebook	entorno_f4.csv
S1: nueve identidades Git	.mailmap y cuentas universitarias	git shortlog -sne
S1: pruebas no ejecutadas	36 pruebas pytest desde el notebook	pruebas_pytest_f4.txt
S1: faltaba el diseño muestral	Estimación ponderada validada con el CDC	validacion_externa_cdc_f4.csv
F3: dos notebooks y dos src	Un notebook central por fase; carpetas documentadas	README
F3: Fibonacci ajeno al proyecto	Memoización en el árbol del YRBS	ADR-0004
F4: f809a58 borró 7 módulos	Restauración (a37fd64) y pruebas de regresión	Bitácora F4.2
S2: el notebook debe responder la pregunta	Sección 15 con tres hallazgos y veredictos	Bitácora F4.23
S2: informe de 33 páginas	Informe de 10 páginas; anexos en F4/resultados/	Bitácora F4.24

Nota. S1: Sumativa 1; F3: Formativa 3; S2: Sumativa 2. Fecha, commit y justificación en changelog.md. **Impacto:** más **modularidad** (tres capas sin ciclos), **rendimiento** (conteos y varianza vectorizados, búsqueda O(1), memoización) y **documentación** verificable (bitácora, ADR, diagramas, pruebas, changelog).

XVIII. Presentación audiovisual

Video de 7 minutos en Canvas Studio con los cuatro integrantes y diez láminas numeradas.

XIX. Referencias

Centers for Disease Control and Prevention. (2024a). *2023 Youth Risk Behavior Survey data*

[Conjunto de datos]. <https://www.cdc.gov/yrbs/data/index.html>

Centers for Disease Control and Prevention. (2024b). *2023 YRBS data user's guide*.

https://www.cdc.gov/yrbs/media/pdf/2023/2023_National_YRBS_Data_Users_Guide508.pdf

Lumley, T. (2010). *Complex surveys: A guide to analysis using R*. Wiley.

<https://doi.org/10.1002/9780470580066>

Python Software Foundation. (s. f.). *timeit — Measure execution time of small code snippets*.

<https://docs.python.org/3/library/timeit.html>

Universidad Andrés Bello. (2026a). *Apunte de la Fase 4: consolidación del proyecto, visualización de datos y comunicación de resultados* [Material docente]. MCDI500 Programación para la Ciencia de Datos.

Universidad Andrés Bello. (2026b). *Guía de desarrollo: Sumativa 3 (Fase 4). Proyecto final integrador* [Material docente]. MCDI500 Programación para la Ciencia de Datos.

Universidad Andrés Bello. (2026c). *Documentación profesional de arquitectura en ciencia de datos*

[Infografía]. MCDI500 Programación para la Ciencia de Datos.

Valkenburg, P. M., Meier, A., & Beyens, I. (2022). Social media use and its impact on adolescent mental health: An umbrella review of the evidence. *Current Opinion in Psychology*, 44, 58–68.

<https://doi.org/10.1016/j.copsyc.2021.08.017>

Verlenden, J. V., Fodeman, A., Wilkins, N., Jones, S. E., Moore, S., Cornett, K., Sims, V., Saelee, R., & Brener, N. D. (2024). Mental health and suicide risk among high school students and protective factors — Youth Risk Behavior Survey, United States, 2023. *MMWR Supplements*, 73(4), 79–86.

<https://doi.org/10.15585/mmwr.su7304a9>

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.

<https://doi.org/10.1038/s41592-019-0686-2>

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

Young, E., McCain, J. L., Mercado, M. C., Ballesteros, M. F., Moore, S., Licitis, L., Stinson, J., Jones, S. E., & Wilkins, N. J. (2024). Frequent social media use and experiences with bullying victimization, persistent feelings of sadness or hopelessness, and suicide risk among high school students — Youth Risk Behavior Survey, United States, 2023. *MMWR Supplements*, 73(4), 23–30.

<https://doi.org/10.15585/mmwr.su7304a3>