

Informe Final, MCDI500 PROGRAMACIÓN PARA LA CIENCIA DE DATOS

Proyecto final integrador Fase 4: análisis, reproducibilidad y comunicación de resultados

Proyecto: uso de redes sociales y salud mental autopercebida en adolescentes (YRBS 2023) ·

Grupo 8

Docente: Dr. Omar Salinas Silva

Estudiantes: Matías Manriquez Ortiz, Daniel Pérez Ramirez, Abigail Robles Chávez, Roberto Sánchez Saldivia.

Repositorio GitHub: <https://github.com/MatiasManriquezO/proyecto-grupo8-mcdi500>

Magíster en Ciencia de Datos e Inteligencia Artificial

Universidad Andrés Bello, Santiago.

Santiago, 29 de septiembre de 2026.

1. Portada e índice

1. Portada e índice.....	2
2. Introducción y contextualización.....	3
3. Definición de la problemática y objetivos del proyecto.....	3
4. Aplicación de herramientas científicas.....	4
5. Reproducibilidad técnica.....	4
6. Control de versiones.....	5
7. Documentación del proceso.....	5
8. Repositorio GitHub actualizado.....	5
9. Diseño de soluciones algorítmicas eficientes.....	5
10. Codificación funcional.....	5
11. Preprocesamiento y transformación del dataset.....	5
12. Validación técnica y verificación del código.....	6
13. Eficiencia y optimización.....	6
14. Diseño estructurado del código.....	6
15. Notebook final ejecutado y documentado.....	7
16. Implementación de código modular y robusto.....	7
17. Programación orientada a objetos.....	7
18. Documentación de arquitectura.....	7
19. Construcción de visualizaciones de datos efectivas.....	7
20. Preprocesamiento y transformación de datos.....	7
21. Visualizaciones analíticas.....	8
22. Metodología del desarrollo técnico.....	9
23. Validación y reflexión técnica.....	10
24. Resultados.....	10
25. Discusión.....	10
26. Conclusiones.....	10
27. Trazabilidad de mejoras.....	11
28. Presentación audiovisual.....	11
29. Bibliografía.....	12
Anexos.....	14
Anexo A. Validación externa contra las cifras publicadas por el CDC.....	14
Anexo B. Modelo logístico ponderado completo.....	14
Anexo C. Orden empírico de crecimiento (timeit, 5.000 a 160.000 filas).....	14
Anexo D. Pruebas y verificación de ejecución.....	15

2. Introducción y contextualización

La adolescencia concentra el inicio de gran parte de los problemas de salud mental y coincide con el uso más intensivo de redes sociales; la relación entre ambos no se reduce a la depresión y se cruza con el sueño y la actividad física (Valkenburg et al., 2022). En 2023, el 28,5 % de los estudiantes de enseñanza media de Estados Unidos reportó que su salud mental no fue buena la mayor parte del tiempo o siempre (Verlenden et al., 2024) y el 77,0 % usaba redes varias veces al día o más (Young et al., 2024). **Relevancia:** a un colegio, a un programa de salud escolar o a quien diseña políticas de bienestar digital le sirve saber cuánto cambia el malestar con la frecuencia de uso y en qué grupo se concentra, para decidir dónde focalizar prevención y consejería.

El proyecto usa el *Youth Risk Behavior Survey 2023* (YRBS), encuesta nacional del CDC con 20.103 estudiantes y 117 variables (Centers for Disease Control and Prevention [CDC], 2024a). La situación que origina el análisis es doble: la pregunta es sustantiva, y los datos exigen programación, porque la encuesta es una muestra estratificada por conglomerados con pesos y tiene hasta 24,4 % de no respuesta. El **propósito** es estimar esa relación de forma representativa y reproducible. Las fases se articulan así: F1 definió el problema y el entorno; F2 construyó el pipeline de datos; F3 lo llevó a clases y midió sus algoritmos; y F4 pondera por el diseño muestral, valida contra el CDC, comunica tres figuras y verifica la ejecución completa. El entregable central es `F4/notebooks/S3_F4_Integracion_Resultados_Grupo8.ipynb`.

3. Definición de la problemática y objetivos del proyecto

Problema. Medir cuánto cambia la proporción de estudiantes con salud mental no buena según su frecuencia de uso de redes (q80, ocho niveles), si el cambio difiere por sexo, si se acompaña de menos sueño (q85) y si persiste al considerar otros factores. El desenlace es q84 resumido en `salud_mental_mala` (1 = «la mayor parte del tiempo» o «siempre», el corte del CDC). **Pregunta central (F1):** ¿qué relación existe entre los patrones de uso de tecnología y los indicadores de salud mental autopercebida y horas de sueño, considerando variables sociodemográficas y de actividad física? **Objetivo general:** analizar esa relación con estimaciones representativas de la población y un flujo reproducible. La Tabla 1 desagrega los objetivos específicos, cada uno con su hipótesis y su evidencia.

Tabla 1. *Objetivos específicos, hipótesis y evidencia que los responde*

Objetivo específico	Hipótesis	Evidencia
OE1. Estimar la proporción con salud mental no buena según la frecuencia de uso	H1: aumenta con el uso	Figura 1
OE2. Determinar si la relación difiere entre sexos	H2: es mayor en el sexo femenino	Figura 2 e interacción
OE3. Describir la proporción que duerme 8 h o más según el uso	H3: disminuye con el uso	Figura 3
OE4. Estimar la asociación ajustada por sexo, edad, raza/etnicidad, sueño y actividad	H4: se mantiene al ajustar	Tabla 3, Figura B1
OE5. Sostenerlo con un flujo reproducible, validado y medido	—	Apartados 4–15

Nota. Las hipótesis derivan de Valkenburg et al. (2022), Young et al. (2024) y del hallazgo muestral de F3. OE1 y OE4 refinan los objetivos 1 y 4 de F1.

Alcance: estimaciones poblacionales con intervalos de confianza y un modelo ajustado; **no aborda** inferencia causal ni imputación. **Restricciones:** encuesta transversal sin variable de fecha; q80 mide frecuencia, no horas ni tipo de uso; 11 de 117 columnas sin fuentes externas; niveles 2 y 3 de uso con menos de 310 casos. **Supuestos:** las respuestas son autopercepción y no diagnóstico; los faltantes son no respuesta y se tratan como ausentes; los pesos del CDC corrigen la no respuesta (CDC, 2024b).

4. Aplicación de herramientas científicas

pandas lee el archivo del CDC y construye cada tabla que se estima o grafica; **NumPy** hace los cálculos vectorizados (`np.bincount`, álgebra del modelo); **SciPy** aporta el cuantil t (Virtanen et al., 2020); **seaborn** fija el tema y **Matplotlib** dibuja, rotula y anota (Waskom, 2021); **timeit** mide (Python Software Foundation, s. f.); **pytest** automatiza las pruebas; y **Jupyter** con **Git/GitHub** integra código, narrativa e historial. El código está en tres capas sin ciclos: `src/` (F1–F2), `F3/src/` y `F4/src/`; el notebook de F4 importa todo y no define clases.

5. Reproducibilidad técnica

Un único `requirements.txt` fija las versiones; F4 agregó `scipy`, `matplotlib`, `seaborn` y `pytest`. La ejecución versionada usó Python 3.13.7, `pandas` 3.0.6 y `NumPy` 2.5.3 en un entorno virtual creado desde ese archivo; el notebook compara versión fijada e instalada y comprueba `sys.prefix != sys.base_prefix`. La evidencia de ejecución completa es programática: `ejecutar_notebooks` copia el repositorio a una carpeta temporal y ejecuta F1, F2 y F3 con `nbcclient`; los tres terminan sin errores (Anexo D).

6. Control de versiones

Al cierre de F3 había 44 commits trazables por integrante gracias a `.mailmap` (Daniel 18, Roberto 14, Matías 9, Abigail 3). El commit `f809a58`, al subir la carpeta `F3/src/` completa, eliminó siete módulos y el notebook de F3 dejó de ejecutarse; se restauraron en `a37fd64`. La Fase 4 se integra desde la rama `fase4` con commits descriptivos de los cuatro integrantes y un *pull request* a `main`.

7. Documentación del proceso

`docs/bitacora_decisiones.md` registra cada decisión con la cifra que la respalda (0.1 a F4.19); `docs/adr/` guarda cinco decisiones de arquitectura con alternativas descartadas; y `changelog.md` se genera desde `git log`. Los fragmentos de código comentados están en el notebook y en este informe.

8. Repositorio GitHub actualizado

El repositorio tiene una carpeta por fase (F1–F4, cada una con datos, notebooks, código y resultados), `tests/`, `docs/` y un README con ejecución, dependencias, estructura y aporte de cada integrante.

9. Diseño de soluciones algorítmicas eficientes

10. Codificación funcional

Cada tarea es una función o clase con parámetros explícitos; el núcleo de F4 se lee en pocas líneas:

```
diseno = DisenoMuestral(datos)                # pesos, 16 estratos, 89 conglomerados
prev = PrevalenciaPonderada(diseno, nivel=0.95)
por_redes = prev.estimar(datos, "salud_mental_mala", por="redes_sociales_cod")
modelo = RegresionLogisticaPonderada(diseno).estimar(datos, "salud_mental_mala", X=X)
```

`DisenoMuestral` valida la entrada (columnas, pesos positivos, sin NA, al menos dos conglomerados por estrato) y define el conglomerado como el par estrato-PSU. La proporción es $p = \sum w_y / \sum w$ y su varianza se obtiene por **linealización de Taylor**: $z = w(y - p) / \sum w$ se suma por conglomerado y $\text{Var}(p) = \sum_h n_h / (n_h - 1) \sum_j (Z_{hj} - \bar{Z}_h)^2$ (Lumley, 2010). Las subpoblaciones usan $z = 0$ fuera del dominio y los intervalos se calculan en escala logit con t de 73 grados de libertad.

11. Preprocesamiento y transformación del dataset

El pipeline de F2, encapsulado en 12 pasos, lleva el archivo del CDC (20.103×117) al conjunto oficial (20.103×26): elimina `orig_rec` (100 % nula), selecciona 11 columnas por código, convierte códigos a

Int64 y escalas a categorías ordenadas, codifica raceeth en ocho indicadores y deriva cinco indicadores 0/1 con los cortes del CDC. **No se imputa:** rellenar q84 con la moda inventaba 4.398 respuestas y desviaba su distribución en 15,3 pp (ADR-0001); cada estimación declara su n (11.602 pares q80 × q84; 10.941 casos completos en el modelo). **No se escala:** estandarizar una ordinal supone distancias iguales, y los pesos extremos son el diseño. El notebook verifica diez propiedades del conjunto y que el pipeline vigente reproduce el CSV de F2 carácter por carácter.

12. Validación técnica y verificación del código

Validación externa: el estimador reproduce al decimal las seis prevalencias y seis intervalos del CDC, como 28,5 % (IC 26,7–30,4) (Anexo A). **Pruebas automatizadas:** 36 pruebas pytest cubren casos normales (una encuesta mínima cuyo 6/9 se calcula a mano), límite (dominio vacío, proporción cero), excepciones (pesos no positivos, estrato con un conglomerado) y regresión de F1–F3. **Verificación cruzada:** las tres varianzas coinciden a 10^{-10} y los coeficientes difieren en $3 \cdot 10^{-15}$ de los de statsmodels.

13. Eficiencia y optimización

La varianza por diseño se calcula en cada estimación; sus tres implementaciones se midieron con timeit (mínimo de cinco repeticiones), tras verificar que dan el mismo resultado, y a seis tamaños para estimar el **orden empírico** (pendiente de $\log(\text{tiempo})$ contra $\log(n)$).

Tabla 2. Varianza por diseño con 20.103 filas, medida con timeit

Implementación	Tiempo (ms)	Veces más lenta	Memoria pico (KiB)	Pendiente (n grande)
np.bincount (adoptada)	0,084	1,0	5,0	0,98
groupby de pandas	1,090	13,0	836,2	0,50
Bucle de Python	3,244	38,8	6,8	1,02

Nota. Fuente: F4/resultados/eficiencia_varianza_f4.csv, orden_empirico_f4.csv Y puntos_de_cruce_f4.csv.

Las tres son $O(n)$ y difieren por la constante. Con pocos datos el costo fijo pesa: groupby supera al bucle solo desde ≈ 5.300 filas, y en la contingencia crosstab es más lento que zip bajo ≈ 32.600 , el rango del proyecto. Se adoptó bincount: gana en todos los tamaños, usa $O(G \cdot k)$ de memoria ($G = 89$) y acepta la matriz $n \times k$ del modelo (ADR-0002). La búsqueda confirma F3: pendiente 0,96 la lineal, 0,10 la binaria y 0,01 el diccionario (Anexo C).

14. Diseño estructurado del código

Cada módulo tiene una responsabilidad: encuesta.py estima, rendimiento.py mide, visualizacion.py

dibuja y `verificacion.py` comprueba. El acoplamiento es bajo: cambiar la estrategia de faltantes modifica **un** archivo (`estrategias.py`). La recursión se usa solo con profundidad dependiente de los datos: el árbol de segmentos de F3 (poda en $n \geq 30$, `lru_cache`) se extiende en F4 por herencia.

15. Notebook final ejecutado y documentado

El notebook de F4 (61 celdas, 31 de código) corre completo con numeración continua, integra F1–F4 con markdown antes de cada bloque, cierra con una verificación final (11 de 11) y guarda en F4/`resultados/` las tablas que cita este informe.

16. Implementación de código modular y robusto

17. Programación orientada a objetos

`EstimadorEncuesta` es una clase base abstracta con el contrato `estimar()`; `PrevalenciaPonderada` y `RegresionLogisticaPonderada` lo implementan de forma distinta (**polimorfismo**), y ambas **encapsulan** el diseño (los pesos salen como copia de solo lectura; `resumen()` antes de `estimar()` lanza `RuntimeError`). `ArbolPrevalenciaPonderada` **hereda** de `ArbolPrevalencia` (F3) y solo redefine `estadisticas()`: la ponderación se agregó sin modificar F3 (ADR-0004). Son clases porque guardan estado; lo demás son funciones.

18. Documentación de arquitectura

`docs/arquitectura.md` sigue la infografía del curso (Universidad Andrés Bello [UNAB], 2026c): objetivo, entradas y salidas por componente, dependencias y cuatro diagramas (flujo, componentes, secuencia y datos). Cada patrón se justifica con su problema: **Strategy**, porque rellenar faltantes inventaba respuestas y cambiar la decisión debía ser un argumento; **Factory**, porque armar 12 pasos a mano repetía constantes; **Observer**, porque cada paso debía registrar filas y tiempo sin mezclarse con la transformación.

19. Construcción de visualizaciones de datos efectivas

20. Preprocesamiento y transformación de datos

El conjunto para modelar no sirve para graficar (UNAB, 2026a): la matriz del modelo tiene 19 columnas de indicadores 0/1. Las figuras usan una **copia interpretable**, `tabla_visual`: una fila por nivel de uso con la etiqueta del codebook, el orden ordinal declarado, el porcentaje ponderado, su intervalo y el **n de cada grupo**, que se muestra en el eje. Como no hubo escalamiento, no hay transformación que revertir.


21. Visualizaciones analíticas

Las tres figuras responden OE1–OE3 en tres actos: contexto, contraste y resolución. Siguen el apunte: título con el hallazgo, eje desde cero, n bajo cada categoría y rojo solo donde está el hallazgo.

Figura 1. Salud mental no buena según la frecuencia de uso de redes (OE1, contexto)

La salud mental no buena se duplica entre quienes no usan redes y quienes las usan cada hora

Porcentaje con salud mental no buena la mayor parte del tiempo o siempre (q84 = 4-5), por frecuencia de uso



Fuente: elaboración propia con YRBS 2023 (CDC, 2024). Estimación con pesos, estratos y conglomerados; IC 95 % en escala logit; n = estudiantes con q80 y q84 respondidas.


Nota. Ponderada con IC 95 % (puntos llenos) y muestral (círculos grises). Fuente: F4/resultados/prevalencia_redes_f4.csv.

Muestra que la proporción sube de 15,5 % (IC 11,8–20,1) sin redes a 33,1 % (IC 30,7–35,6) con uso horario; se infiere que el uso frecuente se asocia con más del doble de malestar, y ponderar marca más el gradiente que la muestra (20,3 % → 35,3 %); límite: los niveles 2–3 tienen 307 y 175 casos. **H1 se sostiene.**

Figura 2. Salud mental no buena por uso de redes y sexo (OE2, contraste)

Con más uso de redes, la salud mental no buena sube 23 puntos en mujeres y 7 en hombres

Porcentaje ponderado con salud mental no buena por uso de redes y sexo (q2); banda = IC 95 %



Fuente: elaboración propia con YRBS 2023 (CDC, 2024). n = estudiantes de ambos sexos con q80 y q84 respondidas.

Nota. Ponderada; la banda es el IC 95 %. Fuente: F4/resultados/prevalencia_redessexo_f4.csv.


Muestra que en el sexo femenino la proporción pasa de 20,9 % a 44,1 % (+23,2 pp) y en el masculino

de 12,6 % a 20,1 % (+7,5 pp); *se infiere* que el gradiente se concentra en las estudiantes, y la interacción del modelo lo confirma (OR 1,49; IC 1,11–2,00); *límite*: las bandas se superponen donde hay pocos casos. **H2 se sostiene.**

Figura 3. Estudiantes que duermen 8 horas o más según la frecuencia de uso (OE3, resolución)

En todos los niveles de uso de redes, menos de un tercio duerme 8 horas o más

Porcentaje ponderado que duerme 8 horas o más en una noche escolar (q85 = 5-7); barras de error = IC 95 %



Fuente: elaboración propia con YRBS 2023 (CDC, 2024). n = estudiantes con q80 y q85 respondidas.

Nota. Ponderada con IC 95 %. Fuente: F4/resultados/sueno_redes_f4.csv.

Muestra que solo 23,2 % duerme 8 horas o más, con 30,6 % (IC 22,6–39,9) sin redes y 21–22 % en los niveles de mayor uso; *se infiere* que el sueño insuficiente es la norma y no explica el gradiente; *límite*: los intervalos se solapan. **H3 no es concluyente**, y el sueño entra al modelo como control.

22. Metodología del desarrollo técnico

Cada fase entregó un insumo verificable a la siguiente. Se eligió programación **estructurada** para el pipeline secuencial, **recursiva** solo con profundidad desconocida (tras descartar la recursión lineal por el límite de Python) y **orientada a objetos** para componentes con estado o variantes, lo que produjo un pipeline que reproduce F2 y estimadores intercambiables. Se eligió ponderar por diseño porque la muestra sobrerrepresenta el malestar, lo que cambió el total de 30,6 % a 28,5 %. Se eligió bincount por las mediciones del apartado 13, lo que dejó cada estimación en fracciones de milisegundo. La colaboración usa ramas, *pull request* y un commit por componente de cada integrante.

23. Validación y reflexión técnica

Tabla 3. Comparación con la fase anterior

Aspecto	Fase 3	Fase 4 y por qué cambió
Alcance de las cifras	Muestra, sin ponderar	Población: el YRBS tiene diseño muestral complejo
No usa → más de una vez por hora	20,3 % → 35,3 %	15,5 % → 33,1 % con IC 95 %
Validación	Pipeline = CSV de F2	+ cifras del CDC y 36 pruebas: un commit borró módulos
Medición	perf_counter y tracemalloc	+ timeit, orden empírico y punto de cruce

Reflexión del grupo: en eficiencia, la notación O no basta porque tres versiones lineales difieren hasta 39 veces; en escalabilidad, un árbol ponderado profundo costaría $O(\text{nodos} \cdot n)$, mejorable precalculando totales por conglomerado; en diseño, la herencia extendió F3 sin tocarlo.

24. Resultados

La regresión logística ponderada (10.941 casos) mantiene la asociación al ajustar por sexo, edad, raza/etnicidad, sueño y actividad (Tabla 4): usar redes más de una vez por hora se asocia con 2,45 veces las chances de salud mental no buena. **H4 se sostiene.** Dormir 8 horas o más reduce las chances a la mitad, coherente con los factores protectores del CDC (Verlenden et al., 2024).

Tabla 4. Odds ratios ajustados de salud mental no buena (selección)

Término (referencia)	OR	IC 95 %	Valor p
Redes: varias veces al día (no usa)	2,03	1,28–3,21	0,003
Redes: más de una vez por hora (no usa)	2,45	1,55–3,85	< 0,001
Sexo femenino (masculino)	2,51	2,15–2,93	< 0,001
Duerme 8 h o más (menos de 8 h)	0,48	0,40–0,58	< 0,001

25. Discusión

Se sostienen H1, H2 y H4, y H3 queda abierta, en línea con Young et al. (2024) y con la heterogeneidad que advierten Valkenburg et al. (2022). **Limitaciones:** diseño transversal sin dirección causal; q80 mide frecuencia y no tipo de uso; la no respuesta (hasta 24,4 %) puede no ser aleatoria; niveles de uso con pocos casos. **Riesgos:** leer los odds ratios como riesgos relativos y generalizar a otros países o años.

26. Conclusiones

En 2023, la salud mental no buena se duplica entre quienes no usan redes y quienes las usan cada hora, la asociación es mucho mayor en el sexo femenino y persiste al ajustar por sueño y actividad; un flujo

modular y probado reprodujo las cifras oficiales al decimal. Se recomienda focalizar prevención en estudiantes de sexo femenino con uso horario, sumar ediciones anteriores del YRBS e incorporar tipo de uso y acoso en línea.

27. Trazabilidad de mejoras

Tabla 5. Observaciones formativas y acciones de mejora

Observación recibida	Acción aplicada	Evidencia
S1: requirements.txt vacío	Versiones fijas, comparadas en el notebook	entorno_f4.csv
S1: nueve identidades Git	.mailmap y cuentas universitarias	git shortlog -sne
S1: pruebas no ejecutadas	36 pruebas <code>pytest</code> desde el notebook	pruebas_pytest_f4.txt
S1: faltaba el diseño muestral	Estimación ponderada validada con el CDC	Anexo A
F3: dos notebooks y dos <code>src</code>	Un notebook central por fase; carpetas documentadas	README
F3: Fibonacci ajeno al proyecto	Memoización en el árbol del YRBS	ADR-0004
F4: <code>f809a58</code> borró 7 módulos	Restauración (<code>a37fd64</code>) y pruebas de regresión	Bitácora F4.2

Nota. S1: Sumativa 1; F3: Formativa 3. Fecha, commit y justificación en `changelog.md`. **Impacto:** más **modularidad** (tres capas sin ciclos), **rendimiento** (conteos y varianza vectorizados, búsqueda $O(1)$, memoización) y **documentación** verificable (bitácora, ADR, diagramas, pruebas, `changelog`).

28. Presentación audiovisual

Video de 7 minutos en Canvas Studio con los cuatro integrantes y diez láminas numeradas.

29. Bibliografía

- Centers for Disease Control and Prevention. (2024a). *2023 Youth Risk Behavior Survey data* [Conjunto de datos]. <https://www.cdc.gov/yrbs/data/index.html>
- Centers for Disease Control and Prevention. (2024b). *2023 YRBS data user's guide*.
https://www.cdc.gov/yrbs/media/pdf/2023/2023_National_YRBS_Data_Users_Guide508.pdf
- Lumley, T. (2010). *Complex surveys: A guide to analysis using R*. Wiley.
<https://doi.org/10.1002/9780470580066>
- Python Software Foundation. (s. f.). *timeit — Measure execution time of small code snippets*.
<https://docs.python.org/3/library/timeit.html>
- Universidad Andrés Bello. (2026a). *Apunte de la Fase 4: consolidación del proyecto, visualización de datos y comunicación de resultados* [Material docente]. MCDI500 Programación para la Ciencia de Datos.
- Universidad Andrés Bello. (2026b). *Guía de desarrollo: Sumativa 3 (Fase 4). Proyecto final integrador* [Material docente]. MCDI500 Programación para la Ciencia de Datos.
- Universidad Andrés Bello. (2026c). *Documentación profesional de arquitectura en ciencia de datos* [Infografía]. MCDI500 Programación para la Ciencia de Datos.
- Valkenburg, P. M., Meier, A., & Beyens, I. (2022). Social media use and its impact on adolescent mental health: An umbrella review of the evidence. *Current Opinion in Psychology*, 44, 58–68.
<https://doi.org/10.1016/j.copsyc.2021.08.017>
- Verlenden, J. V., Fodeman, A., Wilkins, N., Jones, S. E., Moore, S., Cornett, K., Sims, V., Saelee, R., & Brener, N. D. (2024). Mental health and suicide risk among high school students and protective factors — Youth Risk Behavior Survey, United States, 2023. *MMWR Supplements*, 73(4), 79–86.
<https://doi.org/10.15585/mmwr.su7304a9>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–

272. <https://doi.org/10.1038/s41592-019-0686-2>

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

Young, E., McCain, J. L., Mercado, M. C., Ballesteros, M. F., Moore, S., Licitis, L., Stinson, J., Jones, S. E., & Wilkins, N. J. (2024). Frequent social media use and experiences with bullying victimization, persistent feelings of sadness or hopelessness, and suicide risk among high school students — Youth Risk Behavior Survey, United States, 2023. *MMWR Supplements*, 73(4), 23–30. <https://doi.org/10.15585/mmwr.su7304a3>

Anexos

Anexo A. Validación externa contra las cifras publicadas por el CDC

Indicador	Grupo	CDC: % (IC 95 %)	Grupo 8: % (IC 95 %)	% muestral	deff
Salud mental no buena	Total	28,5 (26,7–30,4)	28,5 (26,7–30,4)	30,6	6,74
Salud mental no buena	Femenino	38,8 (36,2–41,4)	38,8 (36,2–41,4)	41,3	5,41
Salud mental no buena	Masculino	18,8 (17,3–20,5)	18,8 (17,3–20,5)	20,0	3,41
Uso frecuente de redes	Total	77,0 (73,5–80,1)	77,0 (73,5–80,1)	78,1	23,51
Uso frecuente de redes	Femenino	81,8 (77,6–85,3)	81,8 (77,6–85,3)	83,2	18,87
Uso frecuente de redes	Masculino	72,9 (69,8–75,8)	72,9 (69,8–75,8)	73,3	8,64

Nota. Cifras del CDC: Verlenden et al. (2024) y Young et al. (2024). deff: efecto de diseño. Fuente:


F4/resultados/validacion_externa_cdc_f4.csv.

Anexo B. Modelo logístico ponderado completo

Figura B1. Odds ratios ajustados de salud mental no buena (OE4)

Uso de redes y salud mental no buena, ajustado por sexo, edad, sueño, actividad y raza

Regresión logística ponderada por diseño; referencia: no usa redes



Fuente: elaboración propia con YRBS 2023 (CDC, 2024); 10.941 casos completos.

Nota. Raza/etnicidad incluida en el modelo (referencia: blanca) y omitida en la figura. Fuente: F4/resultados/modelo_logistico_f4.csv y modelo_interaccion_f4.csv.

Anexo C. Orden empírico de crecimiento (timeit, 5.000 a 160.000 filas)

Problema	Implementación	Pendiente (todos los n)	Pendiente (n grande)	ms con 160.000
Varianza por diseño	np.bincount	0,74	0,98	0,26
Varianza por diseño	groupby	0,31	0,50	2,56
Varianza por diseño	bucle	0,99	1,02	26,26
Contingencia q80 × q84	bincount	0,83	1,15	0,82
Contingencia q80 × q84	crosstab	0,21	0,39	9,57
Contingencia q80 × q84	zip	0,98	0,99	25,43
Contingencia q80 × q84	iterrows	1,00	1,00	2.140,02
Búsqueda de 200 id	diccionario O(1)	0,02	0,01	0,02


Problema	Implementación	Pendiente (todos los n)	Pendiente (n grande)	ms con 160.000
Búsqueda de 200 id	binaria recursiva $O(\log n)$	0,11	0,10	0,73
Búsqueda de 200 id	lineal $O(n)$	0,98	0,96	868,38

Nota. Pendiente de $\log(\text{tiempo})$ contra $\log(n)$: ≈ 1 lineal, ≈ 0 constante o logarítmica. Puntos de cruce: groupby supera al bucle desde ≈ 5.300 filas; crosstab supera a zip desde ≈ 32.600 . Fuente: F4/resultados/orden_empirico_f4.csv y puntos_de_cruce_f4.csv.

Figura C1. Crecimiento del tiempo de la varianza por diseño

Varianza por diseño: bincount es la más rápida en todos los tamaños

timeit: mínimo de 5 repeticiones; pendiente log-log = orden empírico



Fuente: elaboración propia (F4/resultados).

Nota. Escala log-log. Fuente: F4/resultados/crecimiento_f4.csv.

Anexo D. Pruebas y verificación de ejecución

Verificación	Resultado
Pipeline de clases (F3) frente al CSV de F2	Idéntico carácter por carácter
Validaciones del conjunto analítico	10 de 10
Pruebas pytest (tests/)	36 aprobadas en ≈ 10 s
Casos límite y excepciones ejecutados en el notebook	10 de 10 con el resultado esperado
Notebook F1 (22 celdas de código)	OK, 1,4 s
Notebook F2 (30 celdas de código)	OK, 3,0 s
Notebook F3 (54 celdas de código)	OK, 28,6 s
Notebook F4 (31 celdas de código)	Ejecución continua sin errores
Objetivos específicos con su evidencia (figura o tabla)	5 de 5
Huella SHA-256 de los datos (CDC · F2 · requirements)	590ada8d... · fd22a62b... · f1cf03fb...
Lista de verificación final del notebook	11 de 11 comprobaciones
Clases definidas en el notebook F4	0 (todas importadas de F3/src y F4/src)

Nota. Fuente: F4/resultados/pruebas_pytest_f4.txt, casos_limite_f4.csv, verificacion_ejecucion_f4.csv, huellas_f4.csv y lista_verificacion_f4.csv.